

Deep learning 3

1. 自监督式学习 (GPT)

与 BERT 相似，GPT 的训练方式也是自监督式的。

三才深度学习课堂 bilibili

Predict Next Token





图1.1 GPT

根据输入预测下一个 token。



GPT 可以预测下一个 token，那么如何把这种想法应用在其他的地方呢？

论文中，"In-context" Learning，即直接向 GPT 输入 "Translate English to French : cheese => "




图1.2 In-context Learning 的几种方式

这种 learning 方式本质上并不是在训练模型，没有更改任何模型参数，相当于直接提问题，正确率相较于微调模型并不高。




图1.3 上述学习方式在一些任务上的正确率


2.Recent Advances in Pre-trained Language Models

近几年预训练模型的发展（2021-2022）。

这一部分主要介绍 PLM 面临的数据少、模型大、训练慢等问题，并引出两类解决方法：数据高效微调 and 参数高效微调。前者包括 Prompt Tuning、半监督学习，后者包括 Adapter 和 LoRA，核心都是用更少数据或更少参数完成任务适配。

2.1 The Problems of PLMs

- Data scarcity 需要的训练数据规模很大，但是实际上在某个任务上可能并没很多训练数据。
- 模型很大，如果对每个任务都要对整个模型进行微调，需要保存很多个这样模型的版本，空间占用大。
- 模型参数很多，网络比较深，训练速度很慢。



(b) The model size and data size applied by recent NLP PTMs.

图2.1.1 模型大小和数据集大小趋势 (2021)

2.2 The Solutions of Those Problems

2.2.1 Data-Efficient Fine-tuning: Prompt Tuning (Soft Prompt)

早期的想法是人工设计提示词模版去训练模型，那如果这个提示词是由机器学习出来的呢？效果会不会更好。

冻结模型参数，为输入向量加入一组可训练的向量 P 作为提示向量，感性上可以理解为告诉模型具体要完成什么任务，更新参数时候只会更新向量 P 。

可以感性认识为加入了下面的提示：
“请判断下面句子的情感：这部电影很好看。答案是：”

2.2.2 Data-Efficient Fine-tuning: Semi-supervised learning

- Pseudo-labeling, 伪标签
 - a. 先用少量有标签数据训练一个模型；
 - b. 用这个模型去预测无标签数据；
 - c. 把高置信度预测结果当作“伪标签”；
 - d. 再用真实标签 + 伪标签一起训练。

- Consistency Regularization，一致性正则化

原理上：同一个样本，稍微扰动一下，模型输出应该差不多。



“这部电影很好看”

“这部电影挺不错”

2.2.3 Parameter-Efficient Fine-tuning:Adapter

冻结大模型原来的参数，只在 Transformer 每一层中插入一个很小的可训练模块，用这个小模块来适配新任务。

示意图

```
1  输入
2  ↓
3  Self-Attention
4  ↓
5  Adapter
6  ↓
7  Feed Forward
8  ↓
9  Adapter
10 ↓
11 输出
```

例如小的分类任务，训练时候只更新 Adapter 和分类头。

2.2.4 Parameter-Efficient Fine-tuning:LoRA

冻结大模型原来的权重，只训练两个很小的低秩矩阵，用它们来近似“微调时应该产生的权重变化”。

可以把全量微调视为下面公式：

$$W \rightarrow W + \Delta W$$

图2.2.4.1 全量微调

LoRA 来模拟 ΔW ，实际还要将 ΔW 拆成矩阵 B 和 A， $\Delta W = BA$ ，最后完整公式为：

$$h = Wx + \frac{\alpha}{r}BAx$$

图2.2.4.2 LoRA 介入后的线性变换公式

🎉 其中 α 为缩放系数， r 为矩阵的秩

这怎么能和矩阵的秩有关系呢？

📖 实际上 LoRA 之所以训练量少，主要因为参数少。

根据小学二年级就学过的线性代数，一个 3×3 的矩阵，可以由一个 3×1 和一个 1×3 的矩阵得到。

那如果这个 3×3 矩阵是 ΔW ，原先需要更新的9个参数就只需要更新6个参数了。

矩阵的秩又是怎么回事？

$N \times N$ 的矩阵可以由 $N \times 1$ 与 $1 \times N$ 的向量相乘得到，

也可以由 $N \times 2$ 与 $2 \times N$ 的矩阵相乘得到，后续可以写成 $N \times r$ 与 $r \times N$ ，这个 r 就代表了矩阵的秩。

假设原矩阵：

$$\Delta W \in \mathbb{R}^{n \times m}$$

LoRA 取：

$$r = 4$$

那么：

$$B \in \mathbb{R}^{n \times 4}$$

$$A \in \mathbb{R}^{4 \times m}$$

于是：

$$\Delta W = BA$$

图2.2.4.3 上述总结




LoRA 对比 Adapter 有个小小的优势：加入 LoRA 之后，模型的推理速度不变。

3. Anomaly Detection (异常侦测)

Problem Formulation

- Given a set of training data $\{x^1, x^2, \dots, x^N\}$
- We want to find a function detecting input x is similar to training data or not.



Different approaches use different ways to determine the similarity. Created with EverCam: <http://www.camdemv.com>

图3.1 图示

上图表示模型要能甄别出和训练资料不一样的输入。

具体应用：

Applications

- Fraud Detection
 - Training data: 正常刷卡行為, x : 盜刷 ?
 - Ref: <https://www.kaggle.com/ntnu-testimon/paysim1/home>
 - Ref: <https://www.kaggle.com/mlg-ulb/creditcardfraud/home>
- Network Intrusion Detection
 - Training data: 正常連線, x : 攻擊行為 ?
 - Ref: <http://kdd.ics.uci.edu/databases/kddcup99/kddcup99.html>
- Cancer Detection
 - Training data: 正常細胞, x : 癌細胞
 - Ref: <https://www.kaggle.com/uciml/breast-cancer-wisconsin-data/home>

图3.2 应用

如何实现异常侦测？

3.1 分类

我的第一想法也是将其视为一个二分类问题，分成正常与异常两类，但是实际情况并没有这么简单。

先按照我的思路，把这个问题视为分类问题，那么我们需要把正常样本当做一个类去训练，再把异常样本当做一个类去训练。

然后我们就会遇到第一个问题，异常样本很难穷尽。



举个例子，如果我们希望正常样本是一张二次元人物图片，那么所有非二次元人物的图像都应当是异常样本...比如写实人物，风景照，甚至是一个水杯。

这就导致了我们的难以穷尽异常样本。

第二个问题，如果我们要识别网络安全漏洞检测，那么相比正常样本的数量，恰好是含有漏洞的异常样本数量可能不会有很多，训练资料没那么多。



那难道用分类任务的方法去解决这个问题真的行不通吗？

当然可以用分类方法去做，但我们不是将其视为二分类问题，而是我们可以将这个过程视为对正常样本进行分类任务，这样分类的时候，我们可以获得模型对分类的置信分数，那我们根据这个置信分数就可以去判断这是正常样本还是异常样本。

置信分数较高时候是正常样本，较低时候应当是异常样本。




图3.1.1 根据置信分数异常侦测

3.2 AutoEncoder

输入一个正常样本 x ，模型先压缩再还原：

$$x \rightarrow z \rightarrow \hat{x}$$

图3.2.1 公式

训练目标是让正常数据还原得越像越好：

$$Loss = ||x - \hat{x}||$$

图3.2.2 公式

训练完成后：

- 正常样本：模型见过类似模式，重构误差小；
- 异常样本：模型没学过，重构不好，误差大。

所以可以定义异常分数：

$$Score(x) = ||x - \hat{x}||$$

图3.3.3 公式

如果 $Score(x) > \lambda$ 就认为是异常。

3.3 根据样本出现概率

某样本在正常分布下出现概率很低，可判定为异常。

$$Score(x) = -\log p(x)$$

图3.3.4 公式