

# Deep learning 4

## 1.Explainable ML

### 1.1 Goal of Explainable ML

Make people comfortable, 给一个理由。

---

#### **Local Explanation**

Why do you think this image is a cat?

#### **Global Explanation**

What does a “cat” look like?

(not referred to a specific image)



图1.2.1 Local Explainable 和 Global Explanation 的区别

### 1.2 Local Explainable



给模型一张狗的照片，如何知道模型是根据哪些特征判断出这是狗的？

#### 1.2.1 遮挡图片的某一部分

可以遮挡图片的一部分，让模型再去判断，把每个位置都遮挡一遍，可以获得一张热力图。




图1.2.1.1 示意图

## 1.2.2 计算梯度

计算一张图片的 Loss，分别给每一个特征加上一个偏置，判断哪个特征使得 Loss 改变最大。


$$\{x_1, \dots, x_n, \dots, x_N\} \xrightarrow{\text{Saliency Map}} \{x_1, \dots, x_n + \Delta x, \dots, x_N\}$$

pixels

$$e \xrightarrow{\quad} e + \Delta e$$

loss of an example (the difference between model output and ground truth)

$$\left| \frac{\Delta e}{\Delta x} \right| \xrightarrow{\quad} \left| \frac{\partial e}{\partial x_n} \right|$$



Saliency Map



图1.2.2.1 示意图


接下来介绍一下一些限制。

- 生成出的 Saliency Map 可能有很多噪声。


# Limitation: Noisy Gradient



Gazelle  
(瞪羚)



Typical



SmoothGrad

SmoothGrad: Randomly add noises to the input image, get saliency maps of the noisy images, and average them.

图1.2.2.2 某种可以让这种图片相对更清晰的方法

- 计算梯度这个方法在某些情况下可能无效。

计算损失本质上还是在求解偏导数，但是对于一个函数关系而言，很可能出现导数为零的点，而这个导数为零的实际意义并不是代表着这个点在这次分类任务中不重要。



# Limitation: Gradient Saturation

Gradient cannot always reflect importance




图1.2.2.3 示意图

## 1.3 How a network processes the input data?

## 1.4 Global Explanation

在一个模型之中，选取其某一层的输出结果，训练另一个模型去还原这一层的输出，就可以看到原模型在这一层做了什么。

## What does a filter detect?

E.g., Digit classifier

$X^*$  for each filter





图1.4.1 示意图

但是这种方法很有可能会输出一堆噪声。




图1.4.2 噪声



如何找出对于一个分类模型，让它置信度分数最高的图片？

先训练一个可以用地位向量生成图片的模型，然后连接一个分类器，让分类器的分数尽可能高即可。

这部分有点 GAN 的感觉

# Constraint from Generator

- Training a generator




图1.4.3 示意图

## 2. Attacks in NLP

Adversarial Attack（对抗性攻击），通俗来说，就是通过给输入数据添加人类肉眼无法察觉的微小扰动，故意“欺骗”机器学习模型，让它做出完全错误的判断。

### 2.1 Evasion Attacks and Defenses

#### Evasion Attacks in Computer Vision

- Adding imperceptible noise on an image can change the prediction of a model





图2.1.1



NLP 中找到 Adversarial Attack 的方法：

1. 找到一个正面评价的句子
2. 经过 Transformation 生成一堆句子，然后去除不符合原句意的句子（因为要求 Attack 尽量与原句相似）
3. 经过一些组合生成句子，同样去除句意不符合的
4. 再将句子送入模型，如果模型给出负面评价，那就找到了要求的 Attack。

## Evasion Attacks: Four Ingredients



Morris, John, et al. "TextAttack: A Framework for Adversarial Attacks, Data Augmentation, and Adversarial Training in NLP." *Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing: System Demonstrations*. 2020.

19

图2.1.2 示意图

## 3. Adversarial Attack

### 3.1 White Box



# Example of Attack




图3.1.1 Example of Attack



如何进行 Attack (Non-targeted)

1. 确定原输入图片  $x_0$
2.  $x_0$  经过 Network 生成  $y_0$
3. 目标是找一个  $x$ ，经过 Network 生成  $y$ ，初始化  $x = x_0 + \Delta x$
4. 计算  $y_0$  与  $y$  的损失
5. 固定模型参数，不断更新  $\Delta x$  使得损失最大

以上需要知道模型参数。

## 3.2 Black Box

- 不知道模型参数的话，就在同样训练 data 上自己训练一个相似的模型，然后攻击自己的模型。
- 找到一张图片可以成功攻击很多其他的模型，用这张图片去攻击

## 3.3 Universal Adversarial Attack

给很多图片加入同样的噪声，使得这些图片都攻击成功。



## 3.4 Attack in the Physical World

## 3.5 Defense

# 4.Domain Adaptation (领域自适应)

- 有少量的有标注的数据，可以直接拿来微调

如果数据没有标注：

## Domain Adversarial Training




图4.1 适应的具体方法

1. 将 Network 分成两部分，一部分是特征提取，另一部分是分类预测。
2. 训练出一个 Feature Extractor 使得原 data 和新领域的 data 产生的 vector 分布类似。
3. 具体做法利用 GAN 的思想，即训练 Feature Extractor 骗过 Domain Classifier。



但实际上存在很多问题，就比如训练出来的 Feature Extractor 只是为了让两种 input 的分布更接近，而没有真的学到需要提取的特征。

## 5.Self-supervised models

### 5.1 Cross-lingual

BERT 具有跨语言能力，在 BERT 中，观察中英词汇的 Embedding，不同中文词汇的 Embedding 加上同样的向量，可以得到语义对应的英文词汇的 Embedding。

把所有中文词汇的 Embedding 做平均，再把所有英文词汇的 Embedding 做平均，相减可以得到语言之间的向量差距，利用该差距也许可以更好地实现跨语言的能力。

## 5.2 Cross-discipline

BERT 具有跨学科能力，听起来很厉害。

### Cross-discipline Capability

英 中 日

- Applying BERT to **protein, DNA, music classification**

|          | Protein      |           |              | DNA  |      |        |        | Music    |
|----------|--------------|-----------|--------------|------|------|--------|--------|----------|
|          | localization | stability | fluorescence | H3   | H4   | H3K9ac | Splice | composer |
| specific | 69.0         | 76.0      | 63.0         | 87.3 | 87.3 | 79.1   | 94.1   | -        |
| BERT     | 64.8         | 74.5      | 63.7         | 83.0 | 86.2 | 78.3   | 97.5   | 55.2     |
| re-emb   | 63.3         | 75.4      | 37.3         | 78.5 | 83.7 | 76.3   | 95.6   | 55.2     |
| rand     | 58.6         | 65.8      | 27.5         | 75.6 | 66.5 | 72.8   | 95     | 36       |

The pretrained model learns some general skills for the classification.

图5.2.1 跨学科能力

BERT 完全的语言模型，在别的任务上运用 BERT 居然可以有提高，说明 BERT 在语言学习时候，不仅仅学到了跟语言相关的内容...

学了12年英语终于知道自己为什么要学英语了。

What is the use of the findings?

No pre-train: 6.12 F1 score →  
Pre-training on text: 54.22 F1 score

| ID  | text |
|-----|------|
| 1   | you  |
| 2   | he   |
| 3   | she  |
| 4   | the  |
| ... | ...  |





图5.2.2 预训练模型应用

可以看出预训练模型确实很厉害。

## 5.3 Pre-training on Artificial Data

## 6. Deep Reinforcement Learning

# Supervised Learning → RL



It is challenging to label data in some tasks.

图6.1


不知道正确答案是什么的时候，往往可以用到 Reinforcement Learning。

## 7.Meta Learning

Model-Agnostic Meta-Learning(MAML)

# MAML is good because .....

- ANIL (Almost No Inner Loop)



Aniruddh Raghu, Maithra Raghu, Samy Bengio, Oriol Vinyals, Rapid Learning or Feature Reuse? **那所以因为它已经跟好的结果非常接近** MAML, ICLR, 2020

图7.1

Meta Learning 为什么很好，两个可能：

- 找到一个参数，从这个参数可以很快达到不同 Task 上好的结果。
- 找到一个参数，这个参数距离不同 Task 上好的参数更近。

Paper 中得到的结果是右边这个结果。



除了学习初始化的参数之外，还可以学习 Optimizer

# Optimizer

Marcin Andrychowicz, et al., Learning to learn by gradient descent by gradient descent, NIPS, 2016




图7.2 Optimizer 还能训练出来 这是结果



我勒个，除了参数和 Optimizer 之外，Network 架构也可以训练出来。

Network Architecture Search(NAS)

## 7.1 Applications

- Few-shot Image Classification



# Few-shot Image Classification

- Each class only has a few images.



- **N-ways K-shot** classification: In each task, there are **N classes**, each has **K examples**.
- In meta learning, you need to prepare many **N-ways K-shot** tasks as training and testing tasks.

图7.1.1 N-ways K-shot

在每个任务中，有  $N$  个类别，每个类别有  $K$  个样本。

## 7.2 Meta Learning vs Self-supervised Learning

MAML 在训练别的模型的参数的时候，自己也需要有一个参数，这个参数可以是 BERT 的参数（NLP任务中）

## 7.3 Meta Learning vs Knowledge Distillation(知识蒸馏)

# Knowledge Distillation

**Table 1. Knowledge distillation is not compatible with strong augmentation.** (Das et al., 2020; Cui & Yan, 2021)

| Augmentation                       | Teacher acc. | Student acc. |
|------------------------------------|--------------|--------------|
| Normal                             | 73.3         | <b>70.4</b>  |
| LabelSmooth (Szegedy et al., 2016) | 73.3         | 68.1         |
| Mixup (Zhang et al., 2017)         | 74.3         | 67.9         |
| CutMix (Yun et al., 2019)          | <b>76.0</b>  | 68.8         |

**Table 2. Knowledge distillation suffers from teacher-student gap.** (Mirzadeh et al., 2020; Cho & Hariharan, 2019)

| Teacher                     | Teacher acc. | Student (ResNet20) acc. |
|-----------------------------|--------------|-------------------------|
| ResNet32 (He et al., 2016)  | 71.0         | <b>70.8</b>             |
| ResNet56 (He et al., 2016)  | 73.3         | 70.4                    |
| ResNet110 (He et al., 2016) | 75.4         | 70.5                    |
| ResNet164 (He et al., 2016) | <b>75.8</b>  | 69.9                    |

图7.3.1 老师的实力并不一定反映在学生的成果上


老师的实力并不一定反映在学生的成果上。



Can the teacher-network "learn to teach"?

## 7.4 Meta Learning vs Domain Adaptation

# Meta Learning for Domain Generalization



e.g., in initialization, 所以我们就可以说我们去learn这个learning algorithm<sup>A1</sup>

图7.4.1 示意图

在 Domain Adaptation 中，往往没有 Target Domain 的 dataset，但是我们可以从 Training domains 中分出 dataset 作为 Target domain。

# Meta Learning for Domain Generalization





图7.4.2 示意图

这样轮流训练，交替当 Training data 和 Test data 的类似于双向性思想还挺通用。

- BERT 完形填空。
- 交换一个视频中不同帧的位置

## 7.5 Meta Learning vs Life-long Learning

## Problem of Another Level .....



Meta learning itself also face the issue of catastrophic forgetting!

Chelsea Finn, Aravind Rajeswaran, Sham Kakade, Sergey Levine, Online Meta-Learning, ICML, 2019

Pauching Yap, Hippolyt Ritter, David Barber, Addressing Catastrophic Forgetting in Few-Shot Problems, ICML, 2021

图7.5

无限套娃哈哈哈哈哈。